
Análise e Visualização de Dados

Sistema Recife Cultural

Relatório Final

Anderson Gabriel

Débora Souza

Filipe Macedo

Yuri Cavalcanti

Rafael Peixoto

Raphael Vilela

Pedro Gusmão

CESAR School · Ciência da Computação · 2026.1

19 de junho de 2026

Sumário

1	Introdução	3
2	Plano de Análise	3
2.1	Perguntas de análise	3
2.2	Objetivos da comunicação visual	3
2.3	Justificativa dos tipos de gráfico	4
3	Preparação dos Dados	4
3.1	Fontes de dados	4
3.2	Estratégia de augmentação	4
3.3	Etapas de limpeza e transformação	5
3.4	Distribuição das classes	5
4	Análise Exploratória de Dados	5
4.1	Visitação real por teatro — Recife 2023	5
4.2	Sazonalidade	6
4.3	Padrão por teatro e mês	6
4.4	Distribuições das features	7
4.5	Distribuições das features	7
4.6	Correlações	7
4.7	Agrupamentos	8
5	Modelo de Regressão	8
5.1	Configuração	8
5.2	Tendência preço × receita	9
5.3	Qualidade do ajuste e resíduos	9
5.4	Coeficientes e importância das features	10
6	Classificador de No-Show	11
6.1	Configuração	11
6.2	Métricas de desempenho	11
6.3	Matriz de Confusão	12
6.4	Curvas ROC e Precision-Recall	12
6.5	Importância das Features	13
7	Dashboard Interativo	13
7.1	Ferramenta e arquitetura	13
7.2	Estrutura do dashboard	13
7.3	Visualizações do dashboard	14
8	Síntese dos Insights	15
8.1	Limitações	16
9	Conclusão	16

Resumo

Este trabalho apresenta um pipeline completo de análise e visualização de dados aplicado ao sistema Recife Cultural, plataforma de gestão de eventos teatrais da Prefeitura do Recife. A partir de dados públicos de visitação mensal de 2023 (Dados Abertos Recife) e de um dataset semi-sintético de 996 eventos calibrado com esses dados reais, foram construídos dois modelos preditivos: uma Regressão Linear para estimativa de receita ($R^2 = 0,761$; $MAE = R\$ 2.327,84$) e um classificador GradientBoosting para identificação de risco de no-show (acurácia = 73%; $AUC-ROC = 0,795$). A análise revelou que Teatro do Parque e Teatro Luiz Mendonça concentram mais de 50% da visitação anual, que agosto e setembro formam o período de maior demanda, e que ingressos sociais apresentam probabilidade de ausência três vezes maior que ingressos inteiros. Os resultados foram integrados em um dashboard interativo desenvolvido em Next.js e Recharts, publicado na plataforma institucional, permitindo ao gestor cultural acompanhar padrões históricos e obter previsões em tempo real.

Introdução

O Recife Cultural é uma plataforma digital desenvolvida pela CESAR School em parceria com a Prefeitura do Recife para centralizar a gestão de eventos culturais nos teatros municipais. O sistema cobre o ciclo completo de um evento — desde a submissão pelo produtor até a validação do ingresso na catraca — integrando funcionalidades de bilheteria, sorteio, patrocínio e controle de acesso.

Apesar da riqueza de dados operacionais gerados pelo sistema, gestores culturais carecem de ferramentas analíticas que transformem esses registros em informação para a tomada de decisão. Perguntas como “Quais teatros demandam mais atenção programática?”, “Como o preço do ingresso afeta a receita de um evento?” ou “Quais eventos têm maior risco de público ausente?” não encontravam resposta direta na plataforma.

Este trabalho propõe e implementa um pipeline de análise e visualização de dados para o Recife Cultural, estruturado em três frentes: (1) análise exploratória da demanda histórica de teatros em Recife com base em dados públicos de 2023; (2) modelagem preditiva de receita por Regressão Linear e de risco de no-show por GradientBoostingClassifier; e (3) integração dos resultados em um dashboard interativo disponível diretamente na plataforma institucional.

Os dados utilizados combinam fontes abertas da Prefeitura do Recife — visitação mensal real de seis teatros ao longo de 2023 — com um dataset semi-sintético de 996 eventos gerado a partir dessas estatísticas reais, seguindo metodologia de simulação calibrada documentada por Law & Kelton (2000). A ausência de dados históricos de bilheteria individual é uma limitação reconhecida, discutida ao longo do relatório.

O documento está organizado da seguinte forma: a Seção 2 apresenta o plano de análise; a Seção 3 detalha a preparação dos dados; a Seção 4 conduz a análise exploratória; as Seções 5 e 6 descrevem os modelos preditivos; a Seção 7 apresenta o dashboard; a Seção 8 sintetiza os principais achados e limitações; e a Seção 9 conclui o trabalho.

Plano de Análise

Perguntas de análise

1. **P1 — Demanda e sazonalidade:** Quais teatros e períodos do ano concentram maior público em Recife?
2. **P2 — Previsão de receita:** Qual a receita esperada para um evento dado o espaço, o preço do ingresso e o subsídio de patrocínio?
3. **P3 — Risco de no-show:** Qual a probabilidade de ausência do público, considerando o perfil do ingresso e a data?

Objetivos da comunicação visual

- **Gestor:** entender quais teatros e períodos precisam de mais atenção na programação
- **Produtor:** ter uma estimativa de receita antes de submeter o evento
- **Avaliador:** compreender o processo completo sem necessidade de expertise em ML

Justificativa dos tipos de gráfico

Tabela 1: Justificativa de gráficos por princípio de percepção visual

Gráfico	Justificativa (Cleveland & McGill, 1984; Tufte, 2001)
Barras horizontais	Comprimento é o canal visual mais preciso para comparação entre categorias nominais
Linha temporal	Dados contínuos — tendência e pico percebidos naturalmente; área reforça acumulação
Heatmap	Duas variáveis categóricas com valor numérico — cor comunica magnitude eficientemente
Scatter + tendência	Relação entre variáveis contínuas — scatter revela dispersão, linha resume direção
Resíduos	Verificação de homocedasticidade — padrão aleatório indica bom ajuste
Heatmap 2×2	Quatro células — cor por intensidade facilita identificar erros do modelo
Curva ROC	Tradeoff sensibilidade/especificidade em todos os thresholds; AUC é comparável
Cards de métricas	Valores únicos com destaque; hierarquia visual clara para leitura rápida

Preparação dos Dados

Fontes de dados

Tabela 2: Fontes de dados utilizadas

Fonte	Tipo	Formato	Uso
Visitação mensal 2023 — Prefeitura do Recife	Aberta	CSV	Âncora real das correlações
Teatros de Recife	Aberta	CSV	Lista dos espaços culturais
Equipamentos Culturais e de Lazer	Aberta	CSV	Confirma os teatros principais
Preços de ingresso	Simulada	Gerado	Calibrado por faixa Sympla/Eventbrite
No-show por ingresso	Simulada	Gerado	Correlações documentadas na literatura

Estratégia de augmentação

O dataset é **semi-sintético calibrado com dados reais**: a visitação mensal real de 2023 define o volume de eventos por teatro e mês; preços e comportamento de no-show são gerados sinteticamente com correlações documentadas. Esta abordagem segue Law

& Kelton (2000), onde parâmetros reais calibram distribuições sintéticas quando dados históricos completos são indisponíveis.

Etapas de limpeza e transformação

- Remoção de BOM encoding (`utf-8-sig`) no CSV de visitação
- Correção do typo `Novmebro` → `Novembro`
- *Melt* das colunas mensais para formato longo (`teatro × mês × visitantes`)
- Filtro `Tipo == "Teatros"` — exclusão de museus
- Cálculo de `preco_efetivo` com desconto do patrocínio por capacidade, limitado ao mínimo de R\$1,00
- Encoding ordinal de categorias (`OrdinalEncoder`) — justificado pela invariância do Gradient Boosting à ordem
- Split 80/20 estratificado (mantém proporção das classes)

Distribuição das classes

Tabela 3: Distribuição das classes do classificador

Classe	Contagem	%
BAIXO_RISCO	607	≈ 61%
ALTO_RISCO	389	≈ 39%

Análise Exploratória de Dados

Visitação real por teatro — Recife 2023




Figura 1: Visitantes totais por teatro — Recife 2023. Fonte: Dados Abertos Recife.

O Teatro do Parque liderou a visitação em 2023 com aproximadamente 77 mil visitantes, seguido pelo Teatro Luiz Mendonça com cerca de 62 mil. Juntos, esses dois espaços concentraram mais de 50% do público total dos seis teatros municipais analisados. O Teatro Hermilo Borba Filho registrou queda expressiva, reflexo das obras realizadas em agosto e setembro. A disparidade de escala entre os teatros justifica a inclusão de **capacidade** como feature central no modelo de receita, uma vez que o teto físico determina o potencial máximo de arrecadação independentemente do preço.

Sazonalidade




Figura 2: Média mensal de visitantes — sazonalidade real 2023.

A média mensal de visitantes revela sazonalidade clara: agosto e setembro formam o pico de demanda, seguidos por um segundo pico em novembro e dezembro, possivelmente associado ao encerramento da temporada cultural e às festas de fim de ano. Janeiro e fevereiro apresentam os menores volumes, fenômeno consistente com o calendário de Carnaval e férias escolares. Esse padrão sazonal foi incorporado ao dataset como fator multiplicador de demanda, calibrando o número de eventos gerados por mês de acordo com o comportamento histórico real.

Padrão por teatro e mês




Figura 3: Heatmap de visitantes por teatro e mês.

A análise multivariada pelo heatmap teatro × mês revela três comportamentos distintos. O Teatro do Parque exibe concentração nos meses de agosto e setembro, sugerindo

programação fortemente associada ao calendário cultural pernambucano. O Teatro Luiz Mendonça apresenta crescimento progressivo a partir de maio, atingindo o pico em novembro e dezembro — perfil de aquecimento gradual da temporada. O Teatro Hermilo Borba Filho registra ausência total em agosto e setembro em razão de obras, o que distorce sua média anual e justifica tratamento especial em análises comparativas.

Distribuições das features




Figura 4: Distribuições das variáveis dos dois datasets.

Distribuições das features

As distribuições das features do modelo de receita revelam que **preço_efetivo** apresenta deslocamento à esquerda em relação a **preço_inteira** — efeito direto do subsídio de patrocínio que reduz o preço percebido pelo comprador. A **capacidade** exibe distribuição multimodal com picos em 200, 300–400 e 500–750 lugares, refletindo os diferentes portes dos teatros municipais. A **receita_real** segue distribuição aproximadamente log-normal, com mediana em torno de R\$ 12.874. Para o dataset de no-show, a probabilidade segue distribuição normal centrada em 15–18%, com cauda à direita; o threshold de 20% resulta em 39% dos eventos classificados como **ALTO_RISCO**.

Correlações




Figura 5: Matrizes de correlação de Pearson.

O heatmap de correlação do dataset de receita evidencia que **preço_efetivo** e **preço_inteira** apresentam correlação alta entre si ($\approx 0,85$), esperada dado que um deriva do outro. A **capacidade** tem correlação positiva moderada com **receita_real** ($\approx 0,55$), enquanto **preço_efetivo** apresenta correlação negativa — quanto menor o preço efetivo, maior o volume de ingressos e, consequentemente, a receita. No dataset de no-show, **antecedencia_compra_dias** tem correlação positiva com a probabilidade de ausência

($\approx 0,45$): compradores que adquirem o ingresso com muita antecedência têm maior chance de faltar. `preco_inteira` apresenta correlação negativa ($\approx -0,35$) — ingressos mais caros geram maior comprometimento do público.

Agrupamentos




Figura 6: No-show por tipo de ingresso e por faixa de preço.

A análise por tipo de ingresso confirma a hierarquia esperada: ingressos **SOCIAL** apresentam probabilidade mediana de no-show aproximadamente três vezes maior que ingressos **INTEIRA**, com **MEIA_ENTRADA** em posição intermediária. Esse padrão sugere que o comprometimento financeiro do comprador funciona como fator de retenção — quem paga mais valoriza a experiência e comparece. Por faixa de preço, eventos com ingressos até R\$ 30 apresentam taxa de **ALTO_RISCO** próxima de 65%, enquanto eventos acima de R\$ 55 ficam abaixo de 25%. A faixa de preço emerge, portanto, como o agrupamento com maior poder discriminativo para o classificador.

Modelo de Regressão

Configuração

- **Algoritmo:** Regressão Linear (`LinearRegression`, `scikit-learn`)
- **Features:** `preco_efetivo`, `preco_inteira`, `capacidade`, `categoria_cod`
- **Target:** `receita_real` — soma de ingressos por evento

Tendência preço × receita




Figura 7: Dispersão e linha de tendência: preço efetivo × receita real.

A linha de tendência descendente confirma a elasticidade negativa de preço: conforme o preço efetivo aumenta, menos ingressos são vendidos e a receita total tende a diminuir. A cor dos pontos, proporcional à capacidade do teatro, revela que espaços maiores (azul intenso) geram receitas consistentemente superiores para qualquer faixa de preço — a capacidade funciona como amplificador do potencial de arrecadação. Esse comportamento reforça a relevância do subsídio via patrocínio: reduzir o preço efetivo do ingresso pode aumentar o volume de vendas e, conseqüentemente, a receita bruta do produtor, desde que o subsídio não ultrapasse o piso mínimo de R\$ 1,00.

Qualidade do ajuste e resíduos




Figura 8: Predito × real, resíduos × predito e distribuição dos resíduos.

Tabela 4: Métricas do modelo de regressão

Métrica	Valor
MAE (Erro Médio Absoluto)	R\$ 2.327,84
R^2 (Coeficiente de Determinação)	0,761

O gráfico de resíduos versus valores preditos apresenta dispersão relativamente homogênea em torno de zero, indicando homocedasticidade — pressuposto fundamental da regressão linear satisfeito nos dados analisados. Não há padrão sistemático (funil ou curvatura), o que confirma que a relação entre as features e a receita é adequadamente capturada pelo modelo linear. O histograma dos resíduos exibe forma aproximadamente normal centrada em zero, consistente com os pressupostos teóricos. O $R^2 = 0,761$ indica que o modelo explica 76,1% da variância da receita com apenas quatro features, demonstrando bom poder preditivo para um modelo de simples interpretação.

Coeficientes e importância das features




Figura 9: Coeficientes da regressão linear — impacto em R\$ por unidade.




Figura 10: Tendências de receita por categoria de evento.

O gráfico de coeficientes revela a contribuição marginal de cada feature na receita estimada. A **capacidade** apresenta o maior coeficiente positivo: cada assento adicional de lotação máxima contribui significativamente para o potencial de receita. O **preco_inteira** também tem coeficiente positivo — o preço nominal do ingresso sinaliza eventos premium que atraem público disposto a pagar mais. Em contrapartida, o **preco_efetivo** tem coeficiente negativo, capturando o efeito de elasticidade de demanda: preços efetivos maiores resultam em menos vendas e menor receita total. A separação das tendências por categoria confirma que eventos de **MUSICA** geram receitas sistematicamente superiores às demais categorias para qualquer faixa de preço, seguidos por **TEATRO** e **DANCA**.

Classificador de No-Show

Configuração

- **Algoritmo:** GradientBoostingClassifier (`n_estimators=100`, `max_depth=4`)
- **Target:** `alto_risco` — binário (1 se probabilidade > 20%)
- **Split:** 80/20 estratificado

Métricas de desempenho




Figura 11: Acurácia, Precisão, Recall e F1-Score do classificador.

Tabela 5: Métricas de classificação por classe

Classe	Precisão	Recall	F1	Suporte
BAIXO_RISCO	0,75	0,83	0,79	122
ALTO_RISCO	0,68	0,58	0,62	78
Acurácia geral	0,73 (200 amostras)			

Com distribuição de classes desbalanceada (61% BAIXO_RISCO / 39% ALTO_RISCO), a acurácia sozinha é uma métrica enganosa: um classificador ingênuo que previsse sempre BAIXO_RISCO acertaria 61% das amostras sem qualquer utilidade prática. O modelo GradientBoosting atingiu acurácia de 73%, precisão de 68% e recall de 58%

para a classe `ALTO_RISCO`. O recall de 58% significa que o sistema detecta aproximadamente 6 em cada 10 eventos de alto risco — os demais passam sem alerta ao gestor.

O custo operacional de um falso negativo — evento de alto risco classificado como baixo — é consideravelmente maior que o de um falso positivo, pois o gestor não aciona estratégias de retenção (campanhas de lembrete, confirmação de presença) que poderiam reduzir a ausência do público. Por essa razão, o recall é definido como a métrica prioritária de avaliação neste contexto. Uma redução do threshold de classificação de 20% para 15% em períodos de alta demanda (agosto e setembro) pode elevar o recall às custas de mais alertas preventivos desnecessários — tradeoff aceitável quando os teatros operam próximos à capacidade máxima.

Matriz de Confusão




Figura 12: Matriz de confusão — contagem absoluta e normalizada.

[O modelo acertou 101 casos de `BAIXO_RISCO` (Verdadeiro Negativo) e 46 de `ALTO_RISCO` (Verdadeiro Positivo). Os 32 falsos negativos representam eventos de `ALTO_RISCO` classificados incorretamente como `BAIXO` — o erro mais custoso operacionalmente, pois o gestor não recebe alerta. Os 21 falsos positivos geram alertas desnecessários, com custo operacional menor.]

Curvas ROC e Precision-Recall




Figura 13: Avaliação do classificador em todos os thresholds.

[O AUC de 0,795 indica que o modelo tem 79,5% de chance de classificar corretamente um evento `ALTO_RISCO` acima de um `BAIXO_RISCO` escolhido aleatoriamente —

desempenho satisfatório considerando o dataset semi-sintético. A Average Precision de 0,718 confirma que o modelo mantém boa precisão mesmo ao aumentar o recall.]

Importância das Features




Figura 14: Importância relativa das features — GradientBoostingClassifier.

*[O **preco_inteira** lidera com maior importância relativa, seguido de **antecedencia_compra_dias** — confirmando que preço e antecedência da compra são os principais preditores de ausência. **is_fim_de_semana** e **tipo_cod** apresentam importância moderada, enquanto **dia_da_semana** e **categoria_cod** têm menor peso individual.]*

Dashboard Interativo

Ferramenta e arquitetura

O dashboard foi implementado em **Next.js** + **Recharts**, integrado à plataforma Recife Cultural, acessível em <https://recifecultural-frontend.onrender.com>. A escolha por Next.js + Recharts em vez de Streamlit ou Power BI permite que o gestor acesse o painel analítico no mesmo fluxo de trabalho do sistema, sem ferramentas externas.

A arquitetura segue o padrão: Python pré-computa os resultados analíticos → exporta JSONs → endpoints Java servem os dados → Recharts renderiza no frontend.

Estrutura do dashboard

1. **Demanda real** — visitação 2023, sazonalidade, com filtro por teatro
2. **Perfil de no-show** — distribuição por tipo de ingresso e faixa de preço
3. **Modelo de receita** — scatter interativo preço × receita
4. **Avaliação do classificador** — métricas, matriz de confusão, importância das features

Visualizações do dashboard




Figura 15: Visão geral do dashboard — <https://recifecultural-frontend.onrender.com/gestor/inteligencia>

O dashboard de Inteligência & Analytics está organizado em três abas principais: *Simuladores Preditivos*, *Análise de Evento* e *Visualizações Analíticas*. A aba de visualizações analíticas, exibida na figura acima, concentra os painéis baseados nos dados históricos e nos modelos treinados. A hierarquia visual prioriza a seção de Demanda Real no topo, seguida por Perfil de No-Show, Modelo de Receita e Avaliação do Classificador — ordenação que segue a lógica narrativa da análise: primeiro o histórico, depois o diagnóstico de risco e por fim a avaliação técnica do modelo.



Figura 16: Interatividade e segmentação do dashboard.




Figura 17: Seção de avaliação do classificador no dashboard.

A paleta institucional do Recife Cultural — azul #173DB7 e laranja #E94E1B — foi aplicada de forma semântica em todos os gráficos: o azul representa valores positivos ou de referência (visitação, tendência, BAIXO_RISCO), enquanto o laranja sinaliza atenção ou risco (ALTO_RISCO, thresholds, picos de ausência). O filtro por teatro, implementado como dropdown acima dos gráficos de demanda, atualiza simultaneamente o gráfico de barras e a linha de sazonalidade, permitindo comparação entre espaços. A seção de Avaliação do Classificador expõe as métricas reais do modelo (AUC = 0,795, recall = 58%) com transparência sobre as limitações do dataset semi-sintético, reforçando a clareza da comunicação visual exigida pelo princípio de integridade gráfica de Tufte (2001).

Síntese dos Insights

Tabela 6: Principais insights extraídos da análise

Insight	Implicação para o sistema
Teatro do Parque e Luiz Mendonça concentram > 50% da visitação	Dashboard deve destacar esses teatros na visão do gestor
Pico real em agosto e setembro	Eventos neste período têm maior potencial de receita
Preço efetivo tem correlação negativa com receita	Subsídio bem calibrado pode aumentar receita total
SOCIAL tem no-show ≈ 3× maior que INTEIRA	Programas sociais precisam de estratégias de retenção
Preço baixo → alto risco de no-show	Faixa de preço é o preditor mais robusto do classificador
AUC-ROC = 0,795	O modelo discrimina bem ALTO vs BAIXO risco

Limitações

- **Dados sintéticos:** modelos aprendem correlações artificialmente limpas; métricas seriam mais baixas com dados reais
- **Dataset pequeno:** 996 eventos; avaliação robusta requer validação cruzada
- **Sem dados externos:** clima, feriados e concorrência não foram modelados
- **Threshold fixo:** limiar de 20% é heurístico; em produção deveria ser calibrado com Platt Scaling

Conclusão

Este trabalho construiu um pipeline completo de análise e visualização de dados para o Recife Cultural, respondendo às três perguntas de pesquisa propostas. A análise exploratória identificou padrões de demanda historicamente concentrados no Teatro do Parque e no Teatro Luiz Mendonça, com pico sazonal em agosto e setembro. O modelo de regressão linear demonstrou que a capacidade física do espaço e o preço efetivo do ingresso são os principais determinantes da receita, com o subsídio de patrocínio exercendo papel relevante ao ampliar o acesso do público sem reduzir a arrecadação do produtor. O classificador GradientBoosting indicou que ingressos sociais e compras muito antecipadas são os melhores preditores de ausência, com AUC-ROC de 0,795 — resultado satisfatório para um dataset semi-sintético.

A principal limitação do trabalho é a ausência de dados históricos reais de bilheteria individual. Com o acúmulo de transações reais na plataforma, os modelos poderão ser retreinados periodicamente com dados genuínos, aumentando a precisão das previsões e a relevância dos insights para a gestão cultural. Como próximos passos, recomenda-se a calibração do threshold de classificação via Platt Scaling, a incorporação de variáveis externas (clima, feriados, eventos concorrentes) e a expansão do dashboard com alertas automáticos para eventos identificados como ALTO_RISCO, integrando a camada analítica diretamente ao fluxo operacional da plataforma.

Referências

- CLEVELAND, W.S.; MCGILL, R. Graphical Perception: Theory, Experimentation, and Application. *JASA*, v. 79, n. 387, p. 531–554, 1984.
- LAW, A.M.; KELTON, W.D. *Simulation Modeling and Analysis*. McGraw-Hill, 2000.
- TUFTE, E.R. *The Visual Display of Quantitative Information*. Graphics Press, 2001.
- Prefeitura do Recife. *Dados Abertos Recife*. Disponível em: <https://dados.recife.pe.gov.br>. Acesso em: jun. 2026.